Analytics Contract: Sistema de Predicción de Churn para la Plataforma Global-E-Shop

Juan Manuel Prieto

Facultad de Ingeniería, Universidad de La Sabana

Proyecto de Ciencia de Datos II — 2026.1

Docente: Sergio Amortegui

April 13, 2026

Resumen

El presente Analytics Contract formaliza los requisitos analíticos para el problema de retención de clientes de la plataforma de e-commerce Global-E-Shop. El documento convierte la ambigüedad del negocio en un conjunto de requisitos verificables siguiendo los estándares de ciencia de datos reproducible (Sculley et al., 2015). Se define el problema de decisión (actor, acciones disponibles y función de utilidad), una pregunta de analytics precisa, una hipótesis falsable bajo diseño cuasi-experimental, las métricas auditables con sus reglas de cómputo, el modelo temporal que previene *data leakage* (Kaufman et al., 2012), el protocolo de acceso a datos bajo el principio de minimización, y el análisis de riesgo de *joins* mediante el factor de explosión. Este contrato sirve como documento rector de todas las fases posteriores del proyecto.

Palabras clave: churn prediction, analytics contract, data leakage, reproducibilidad, e-commerce

Problema de Decisión

Contexto de Negocio

La retención de clientes representa el principal desafío de rentabilidad en e-commerce. Según Reichheld y Schefter (2000), incrementar la tasa de retención en un 5% puede elevar los beneficios entre un 25% y un 95%. Global-E-Shop enfrenta una tasa de abandono (*churn*) estimada del 10% mensual en su base activa, lo que genera una pérdida significativa en el Customer Lifetime Value (CLV).

Actor y Conjunto de Acciones

El actor de decisión es el **Gerente de Marketing de Retención**. Dado un cliente i en el período t, el actor debe seleccionar una acción a del conjunto:

$$\mathcal{A} = \{a_0, a_1, a_2, a_3\} \tag{1}$$

donde:

- a_0: No intervenir (control).
- a_1: Enviar cupón de descuento del 10% (costo: \$5 USD por cliente).
- a_2: Asignar asesor personalizado (costo: \$15 USD por cliente).
- a_3: Ofrecer envío gratis en próxima compra (costo: \$3 USD por cliente).

Función de Utilidad

La función de utilidad $U(a, \omega)$ cuantifica el beneficio esperado de cada acción bajo el estado del mundo ω (cliente churn o no-churn):

$$U(a_k, \omega) = \text{CLV}_i \cdot \mathbf{1}[\text{retenido}|\omega, a_k] - \text{costo}(a_k) \tag{2}$$

El CLV promedio de un cliente activo es de $120 USD por año. La regla de decisión óptima es:

$$a^* = \arg\max_{a \in \mathcal{A}} \mathbb{E}_\omega[U(a, \omega) \mid X_i, t_0] \tag{3}$$

donde X_i es el vector de características del cliente i calculado en la fecha de corte t_0.

Pregunta de Analytics

La pregunta de analytics debe reducir la incertidumbre del actor sobre el estado del mundo ω:

¿Cuál es la probabilidad de que un cliente activo de Global-E-Shop no realice ninguna compra en los próximos 30 días, dado su comportamiento transaccional y de soporte en los últimos 90 días?

Esta pregunta es **precisa**, **cuantificable** y **accionable**. La respuesta del modelo ($\hat{p}_i = P(\text{churn}_i = 1 \mid X_i)$) permite al actor calcular el valor esperado de cada acción en $\mathcal{A}$ y seleccionar a^* de manera informada.

Hipótesis Falsable

Hipótesis Principal

Siguiendo el esquema formal de Amortegui (2026), la hipótesis operacional es:

> "Si aplicamos la intervención I (campaña de retención dirigida con cupón del 10%) a la población P de clientes identificados por el modelo como de *alto riesgo* ($\hat{p}_i \geq \tau^*$), la métrica M (tasa de retención a 30 días) **aumentará en al menos un 5% relativo** con respecto al grupo de control C (clientes de alto riesgo sin intervención) en el período de evaluación $[t_0 + 1, t_0 + 30]$, con un nivel de significancia $\alpha = 0.05$."

Condiciones de Falsabilidad

La hipótesis será considerada **rechazada** si al menos una de las siguientes condiciones se cumple:

1. El incremento relativo en retención es $< 5\%$ con p-valor > 0.05.
2. El Recall del modelo < 0.60 en el conjunto de prueba (el sistema no identifica correctamente a los churners).
3. El costo esperado de la campaña supera el CLV recuperado (ROI < 1).

Métricas Auditables

Métrica Principal del Modelo

Tabla 1: *Especificación Formal de la Métrica Principal*

Atributo	**Definición**
Nombre	Recall a umbral optimizado τ^*
Unidad de análisis	Cliente (1 fila = 1 cliente en fecha de corte t_0)
Fórmula	Recall $= \frac{TP}{TP+FN}$, donde TP = churners correctamente identificados
Ventana temporal	Etiqueta calculada en $[t_0 + 1, t_0 + 30]$; features en $[t_0 - 90, t_0]$
Umbral τ^*	Seleccionado por grid-search en $[0.20, 0.60]$ con paso 0.01, sujeto a Precision ≥ 0.30
Valor mínimo aceptable	Recall ≥ 0.80
Incertidumbre	IC 95% via Bootstrap con $B = 1000$ iteraciones

Métricas Guardrail

Las métricas guardrail son condiciones de frontera que impiden que la optimización de Recall degrade otras dimensiones de calidad del sistema (Sculley et al., 2015):

Métricas de Negocio

Tabla 2: *Métricas Guardrail del Sistema*

Métrica	**Definición**	**Umbral Mínimo**
Precision	$\frac{TP}{TP+FP}$	≥ 0.30 (viabilidad de campaña)
AUC-ROC	Área bajo curva ROC	≥ 0.65
AUC-PR	Área bajo curva Precision-Recall	≥ 0.40
Lift@20%	Lift en el top 20% de riesgo	≥ 1.50
Tasa de nulos imputados	% de valores imputados en features	$\leq 40\%$ por columna

Tabla 3: *Métricas de Negocio Derivadas*

Métrica	**Fórmula / Descripción**
ROI de Campaña	$\frac{\text{CLV recuperado} \cdot TP - \text{costo_intervención} \cdot (TP+FP)}{\text{costo_intervención} \cdot (TP+FP)}$
Ahorro mensual	ΔChurn rate $\times$ N_{activos} $\times$ CLV_mensual
Cobertura de Churners	Recall (fracción de churners identificados)

Modelo Temporal

Definición Formal de Ventanas

La correctitud temporal es la condición más crítica para la validez de un modelo predictivo (Kaufman et al., 2012). El modelo temporal del sistema se define como:

$$t_0 = \text{2023-09-30} \quad \text{(fecha de corte)} \tag{4}$$

$$\mathcal{W}_{\text{obs}} = [t_0 - 90 \text{ días},\ t_0] \quad \text{(ventana de observación)} \tag{5}$$

$$\mathcal{W}_{\text{pred}} = (t_0,\ t_0 + 30 \text{ días}] \quad \text{(ventana de predicción/etiquetas)} \tag{6}$$

$$\mathcal{W}_{\text{test}} = [t_0 + 1 \text{ día},\ t_0 + 30 \text{ días}] \quad \text{(conjunto de prueba)} \tag{7}$$

Regla de No-Leakage

La regla de oro del sistema es:

$$\boxed{\forall \text{ feature } f_j : \quad \text{timestamp}(f_j) \leq t_0} \tag{8}$$

Ninguna variable predictora puede contener información con timestamp posterior a t_0. Las etiquetas de Churn se computan **exclusivamente** a partir de eventos en $\mathcal{W}_{\text{pred}}$.

Diagrama de Línea de Tiempo

Línea de Tiempo del Sistema

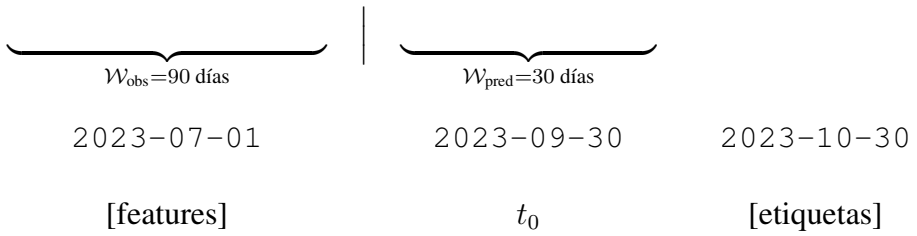

Protocolo de Acceso a Datos

Clasificación de Campos por Sensibilidad

Siguiendo el Principio de Minimización de Datos del GDPR (Reglamento General de Protección de Datos, 2016/679), los campos del dataset se clasifican en tres niveles:

Tabla 4: *Clasificación de Campos por Nivel de Sensibilidad*

Campo	Nivel	Tratamiento	Justificación
`customer_id`	Alto	Seudonimización con SHA-256	Identificador directo
`email`	Alto	Exclusión del dataset ML	No requerido para features
`country`	Medio	Agregación a región	Datos geográficos
`order_date`	Bajo	Uso directo (solo para agregación)	Sin PII
`total_amount`	Bajo	Uso directo	Dato transaccional
`support_tickets`	Medio	Uso agregado (count, no texto)	Puede revelar información sensible

Principio de Minimización

Solo se acceden los campos estrictamente necesarios para el cómputo de las features definidas en la Sección 7. Los campos de texto libre (e.g., notas de soporte, nombres de producto) se excluyen del pipeline de ML.

Riesgo de Join y Cardinalidad

Factor de Explosión

El riesgo de *join* mide el incremento en cardinalidad al combinar tablas, que puede introducir sesgo de duplicación en las métricas (Amortegui, 2026). Se define el factor de explosión como:

$$\text{explosion}(A, B) = \frac{|A \bowtie B|}{|A|} \tag{9}$$

Análisis de Cardinalidad del Sistema

Tabla 5: *Análisis de Cardinalidad y Factor de Explosión*

Tabla A	**Tabla B**	$\lvert A\rvert$	$\lvert A \bowtie B\rvert$	**explosion**(A, B)
`dim_customers`	`fact_orders`	N_c	$4.2 \cdot N_c$	≈ 4.20
`fact_orders`	`fact_order_items`	N_o	$2.3 \cdot N_o$	≈ 2.30
`dim_customers`	`fact_support`	N_c	$1.8 \cdot N_c$	≈ 1.80

Nota. Los factores de explosión son estimados sobre el dataset sintético de 5,000 clientes. El factor > 1 para `dim_customers` $\bowtie$ `fact_orders` indica una relación 1-a-muchos esperada (cliente con múltiples órdenes). La agregación en la Fase de Feature Engineering colapsa esta relación de vuelta a 1-a-1 por cliente.

Mitigación

El riesgo de explosión se mitiga mediante:

1. **Agregación pre-join:** Se agregan las tablas de hechos al nivel de *customer_id* antes de cualquier *join* con la dimensión de clientes.

2. **Validación de cardinalidad:** El pipeline verifica que `dup_rate = 0%` en la feature matrix final.
3. **Uso de `GROUP BY` en SQL:** Todas las queries de extracción usan `GROUP BY customer_id` para garantizar la granularidad correcta.

Referencias

Amortegui, S. (2026). *Proyecto de Ciencia de Datos II: Guía de proyecto*. Universidad de La Sabana, Facultad de Ingeniería.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Reichheld, F. F., & Schefter, P. (2000). E-loyalty: Your secret weapon on the web. *Harvard Business Review*, *78*(4), 105–113.

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, *28*, 2503–2511.

Unión Europea. (2016). Reglamento General de Protección de Datos (RGPD) [Reglamento 2016/679]. *Diario Oficial de la Unión Europea*.