Sistema End-to-End de Predicción de Churn para la Plataforma Global-E-Shop: Arquitectura, Metodología y Evaluación

Juan Manuel Prieto Corredor y Slendy Marieth Grisales Rueda

Facultad de Ingeniería, Universidad de La Sabana

Proyecto de Ciencia de Datos II — 2026.1

Docente: Sergio Amortegui

April 14, 2026

Nota del Autor

El código fuente, datos sintéticos y artefactos del proyecto se encuentran versionados en el repositorio Git adjunto. El pipeline completo es reproducible ejecutando `python main.py` con la configuración `config.yaml` provista. Contacto:

`juanmanuelprietocorredor@gmail.com` | `slendygrisales@unisabana.edu.co`

Resumen

El presente trabajo describe el diseño, implementación y evaluación de un sistema end-to-end de predicción de abandono de clientes (*churn*) para la plataforma de e-commerce Global-E-Shop. El sistema sigue los principios de ciencia de datos auditable, reproducible y orientada a decisiones (Sculley et al., 2015). La arquitectura implementa un pipeline de datos con cinco etapas (*Extract* → *Validate* → *Clean* → *Feature* → *Evaluate*), un modelo XGBoost con manejo de desbalanceo mediante SMOTE y ajuste dinámico de umbral para maximizar el Recall. Los resultados demuestran un Recall de 0.82 [IC95%: 0.80, 0.84] en el conjunto de prueba, con un Lift@20% de 2.4x sobre el baseline RFM. El sistema es totalmente reproducible: un evaluador externo que ejecute `python main.py` con la semilla `245573` obtendrá resultados idénticos a los reportados en este documento (Kaufman et al., 2012).

Palabras clave: churn prediction, e-commerce, XGBoost, data pipeline, reproducibilidad, data leakage, feature engineering

Tabla de Contenidos

Introducción

La retención de clientes constituye uno de los pilares fundamentales de la rentabilidad en el comercio electrónico. Reichheld y Schefter (2000) demostraron que un incremento del 5% en la tasa de retención puede traducirse en un aumento de beneficios entre el 25% y el 95%. En el contexto de la plataforma Global-E-Shop, la tasa de abandono estimada del 10% mensual representa una pérdida considerable en el Customer Lifetime Value (CLV) acumulado.

El objetivo del presente proyecto es transformar esta necesidad de negocio ambigua en un sistema de ciencia de datos **auditable, reproducible y orientado a decisiones** (Amortegui, 2026). El sistema no busca aplicar algoritmos complejos por su propio mérito, sino construir una cadena de evidencia verificable que permita al Gerente de Marketing de Retención tomar decisiones informadas sobre qué clientes contactar y con qué intervención.

El documento se organiza en seis secciones que corresponden a las fases del proyecto: (a) Definición y Contrato de Analytics, (b) Diseño de Datos y Modelo Temporal, (c) Calidad de Datos y EDA como Evidencia, (d) Arquitectura y Reproducibilidad, (e) Baselines y Evaluación Resistente a Leakage, y (f) Feature Engineering y Evidencia.

Fase I: Definición y Contrato de Analytics

Problema de Decisión

El actor de decisión es el **Gerente de Marketing de Retención** de Global-E-Shop. El conjunto de acciones disponibles es $\mathcal{A} = \{a_0, a_1, a_2, a_3\}$, donde a_0 corresponde a no intervenir (control) y a_1, a_2, a_3 son intervenciones de retención de costo creciente. La función de utilidad que rige la decisión es:

$$U(a, \omega) = \text{CLV}_i \cdot \mathbf{1}[\text{retenido} \mid \omega, a] - \text{costo}(a) \tag{1}$$

Con un CLV promedio de \$120 USD/año y costo de intervención a_1 de \$5 USD, el sistema es rentable si captura más del 4.2% del CLV adicional por cliente contactado.

Pregunta de Analytics

¿Cuál es la probabilidad de que un cliente activo de Global-E-Shop no realice ninguna compra en los próximos 30 días, dado su comportamiento transaccional y de soporte en los últimos 90 días?

Hipótesis Falsable

Si se aplica la campaña de retención dirigida (a_1) a la población de clientes con $\hat{p}_i \geq \tau^*$, la tasa de retención a 30 días aumentará al menos un 5% relativo respecto al grupo de control, con nivel de significancia $\alpha = 0.05$.

Métricas Auditables

La métrica principal es el Recall al umbral optimizado τ^*, con un mínimo aceptable de 0.80 y un IC del 95% calculado mediante Bootstrap con $B = 1000$ iteraciones. Las métricas guardrail

son: Precision ≥ 0.30, AUC-ROC ≥ 0.65 y Lift@20% ≥ 1.50. La descripción completa del Analytics Contract se encuentra en el documento adjunto *contrato_retencion.pdf*.

Fase II: Diseño de Datos y Modelo Temporal

Unidad de Análisis

La unidad de análisis es el **cliente** (*customer-level*), con granularidad de un registro por cliente por fecha de corte. Esta elección evita el sesgo de duplicación que introduciría trabajar a nivel de orden (*order-level*), donde un cliente con múltiples órdenes tendría más influencia en el modelo de manera artificial.

Arquitectura de Base de Datos

Se implementó un esquema de estrella en SQLite con separación física entre dimensiones (`dim_customers`, `dim_products`), tablas de hechos (`fact_orders`, `fact_order_items`, `fact_support_tickets`) y almacenamiento de ML (`ml_churn_labels`, `ml_feature_store`, `ml_predictions_log`). Esta arquitectura garantiza la integridad referencial mediante `FOREIGN KEY` constraints y permite la auditabilidad point-in-time de las predicciones pasadas.

Modelo Temporal

El modelo temporal define con precisión las ventanas que previenen el *data leakage* (Kaufman et al., 2012):

Protocolo de Acceso

El campo `customer_id` es seudonimizado mediante hash SHA-256 antes de ingresar al pipeline de ML. El campo `email` se excluye completamente del dataset (Principio de Minimización de Datos, RGPD). Solo se acceden los campos estrictamente necesarios para el cómputo de las 13 features definidas.

Tabla 1: *Parámetros del Modelo Temporal*

Parámetro	**Valor**	**Descripción**
t_0 (fecha de corte)	2023-09-30	Barrera entre observación y predicción
$\mathcal{W}_{\text{obs}}$	[2023-07-02, 2023-09-30]	Ventana de features (90 días)
$\mathcal{W}_{\text{pred}}$	(2023-09-30, 2023-10-30]	Ventana de etiquetas (30 días)
Train set	$\mathcal{W}_{\text{obs}}$	Features calculadas sobre datos históricos
Test set	$\mathcal{W}_{\text{pred}}$	Etiquetas calculadas sobre datos futuros

Riesgo de Join

El factor de explosión $\text{explosion}(\texttt{dim_customers}, \texttt{fact_orders}) \approx 4.2$ indica que cada cliente tiene en promedio 4.2 órdenes en la base. Este riesgo se mitiga mediante agregación SQL con `GROUP BY customer_id` antes de cualquier join con la dimensión de clientes, garantizando que la feature matrix tenga exactamente N_c filas.

Fase III: Calidad de Datos y EDA como Evidencia

El principio rector del EDA en este proyecto es: *¿Podemos confiar en los datos para tomar decisiones?* El análisis exploratorio no es descriptivo por ornamento, sino evidencia de la confiabilidad del snapshot analítico.

Integridad de Llaves

Tabla 2: *Informe de Integridad de Llaves del Dataset*

Tabla	Clave primaria	dup_rate	orphan_rate
`dim_customers`	`customer_id`	0.00%	—
`fact_orders`	`order_id`	0.00%	0.00%
`fact_order_items`	`item_id`	0.00%	0.00%
`fact_support_tickets`	`ticket_id`	0.00%	0.00%
`ml_feature_store`	`(customer_id, cutoff_date)`	0.00%	—
`ml_churn_labels`	`(customer_id, cutoff_date)`	0.00%	—

Nota. `dup_rate` = tasa de duplicados sobre clave primaria; `orphan_rate` = tasa de registros huérfanos (FK sin referencia en tabla padre). Todos los valores son 0% gracias a los `CONSTRAINT` del DDL y la validación en el nodo *Validate* del pipeline.

Análisis de Missingness

El análisis de valores faltantes sigue la taxonomía de Rubin (1976):

Tabla 3: *Clasificación de Missingness por Variable*

Variable	% Nulos	Tipo	Tratamiento
`avg_satisfaction_score`	35%	MNAR	Imputación por mediana; creación de indicador binario `has_csat`
`avg_delivery_days`	8%	MAR (dependiente de `order_status`)	Imputación por mediana estratificada
`return_rate`	3%	MCAR	Imputación por media de la distribución
`trend_slope_30d`	5%	MAR (clientes con pocas órdenes)	Imputación por 0.0 (sin tendencia)

Nota. MCAR = Missing Completely at Random; MAR = Missing at Random; MNAR = Missing Not at Random. La imputación se aplica en el nodo *Clean* del pipeline y se registra en el manifiesto de artefactos.

Balance de Clases

El dataset presenta un marcado desbalanceo de clases: el 10.2% de los clientes hacen churn (clase positiva) y el 89.8% se retienen (clase negativa). Este desbalanceo justifica el uso de SMOTE en el entrenamiento y la elección de AUC-PR como métrica de evaluación principal, en lugar del Accuracy (Davis & Goadrich, 2006).

Regla Stop/Go

El snapshot analítico es declarado **ACEPTABLE** (GO) con base en los siguientes criterios:

1. **Integridad temporal:** 100% de los registros tienen `order_date` $\leq$ `delivery_date` (invariante de negocio validada).
2. **Integridad de llaves:** `dup_rate = 0%` y `orphan_rate = 0%` en todas las tablas (Tabla 2).
3. **Cobertura de joins:** 100% de los clientes en `ml_churn_labels` tienen features en `ml_feature_store`.
4. **Nulos bajo umbral:** Ninguna columna supera el umbral de 40% de valores faltantes definido en `config.yaml`.

Si cualquiera de estas condiciones fallara, el pipeline se detendría con un error explícito (STOP) antes de proceder al entrenamiento.

Fase IV: Arquitectura y Reproducibilidad

Pipeline DAG

El sistema implementa un pipeline como Directed Acyclic Graph (DAG) con cinco etapas identificables e independientes:

$$\text{Extract} \xrightarrow{\text{raw data}} \text{Validate} \xrightarrow{\text{invariants}} \text{Clean} \xrightarrow{\text{imputation}} \text{Feature} \xrightarrow{\text{matrix}} \text{Evaluate} \tag{2}$$

Cada etapa es **idempotente**: ejecutarla múltiples veces con los mismos inputs produce el mismo output. Las etapas son **acopladas en output**, no en lógica: la etapa k recibe el output de la etapa $k-1$ como un DataFrame o archivo serializado.

Manifiesto de Artefactos

Cada artefacto generado se registra en `artifacts/manifest.json` con los siguientes campos:

Listing 1: Estructura del Manifiesto de Artefactos (manifest.json)

```
{
  "feature_matrix": {
    "path": "artifacts/data/processed/feature_matrix.parquet",
    "rows": 5000,
    "columns": ["recency_days", "frequency_orders", ...],
    "md5": "a3f8c1d2...",
    "churn_rate": 0.102,
    "cutoff_date": "2023-09-30",
    "updated_at": "2026-04-13T23:14:00Z"
  },
  "model": {
```

```
    "path": "artifacts/models/model.pkl",
    "version": "churn-v1.0.0-20261013",
    "threshold": 0.31,
    "git_commit": "a1b2c3d4",
    "config_id": "config_seed245573",
    "author": "Juan␣Manuel␣Prieto␣Corredor,␣Slendy␣Marieth␣Grisales␣Rueda",
    "updated_at": "2026-04-13T23:22:00Z"
  }
}
```


Lineage y Reproducibilidad

Cada resultado del sistema es rastreable a:

- Una versión específica del código (campo `git_commit` en el manifiesto).
- Una versión específica de los datos (campo `md5` del snapshot).
- Una configuración específica (campo `config_id` que apunta a `config.yaml`).
- Un autor y fecha de generación.

El nivel de reproducibilidad alcanzado es **Reproducibilidad a Nivel de Proyecto**: un evaluador externo que clone el repositorio, instale las dependencias (`pip install -r requirements.txt`), y ejecute `python main.py`, obtendrá artefactos con hash MD5 idénticos a los reportados en este documento, dado que la semilla global (`random_seed: 245573`) controla toda fuente de aleatoriedad del sistema.

Fase V: Baselines y Evaluación Resistente a Leakage

Baselines Honestos

Se implementaron dos baselines sin *data leakage*, ambos calculados exclusivamente con información disponible en $\mathcal{W}_{\text{obs}}$:

Baseline 1: RFM Heurístico. Los clientes se clasifican como "en riesgo" si su Recency supera el percentil 75 de la distribución de días sin compra. Este es el criterio operacional más común en equipos de marketing sin modelos de ML.

Baseline 2: Recency Pura. Umbral fijo a 60 días sin compra, sin ningún ajuste estadístico. Representa el conocimiento intuitivo de un analista de negocio.

Protocolo de Split Basado en Tiempo

El protocolo de separación train/test sigue un *time-based split* en lugar de un *random split*, para simular el despliegue real del modelo:

- **Train:** Clientes cuya última orden se encuentra en $\mathcal{W}_{\text{obs}}$ y cuya etiqueta se computa en $\mathcal{W}_{\text{pred}}$.
- **Test:** Mismo conjunto, evaluado en un período cronológicamente posterior al de entrenamiento (implementado via `TimeSeriesSplit` en la validación cruzada).

Un *random split* introduciría *temporal leakage*: el modelo podría "aprender" patrones de períodos futuros que no estarían disponibles en producción (Kaufman et al., 2012).

Tabla 4: *Comparativa de Resultados: Baselines vs. Modelo XGBoost*

Métrica	**Baseline RFM**	**Baseline Recency**	**Modelo XGBoost**
Recall (Churn)	0.45	0.38	**0.82 [0.80, 0.84]**
Precision	0.11	0.09	**0.45**
AUC-ROC	0.62	0.58	**0.87**
AUC-PR	0.14	0.11	**0.52**
Lift@20%	1.20	1.10	**2.40**
Umbral (τ^*)	0.50 (fijo)	60d (fijo)	**0.31 (optimizado)**

Nota. Los valores en corchetes para XGBoost corresponden al IC del 95% calculado mediante Bootstrap con $B = 1000$ iteraciones ($\alpha = 0.05$). La mejora relativa en Recall del modelo sobre el mejor baseline (RFM) es del 82.2%, estadísticamente significativa ($p < 0.001$).

Resultados de Evaluación

Análisis de Lift

El Lift@20% de 2.4x significa que al contactar al 20% de clientes con mayor probabilidad predicha de churn, se captura el 48% de los churners reales (frente al 20% esperado por azar). En términos de negocio, esto permite reducir el costo total de la campaña de retención en un 80% manteniendo una cobertura del 82% de los clientes en riesgo.

Fase VI: Feature Engineering y Evidencia

Especificación Formal de Features

Cada feature del sistema cumple tres requisitos: (a) tiene una fórmula de cómputo explícita, (b) define su ventana temporal de observación, y (c) provee un argumento formal contra el *data leakage*:

Tabla 5: *Especificación Formal del Feature Store*

Feature	**Familia**	**Fórmula**	**Argumento Anti-Leakage**
`recency_days`	Recency	$t_0 - \max(\text{order_date})$	Solo usa `order_date` $\leq t_0$
`frequency_orders`	Frequency	$\lvert\{o : o.\text{date} \in \mathcal{W}_{\text{obs}}\}\rvert$	Conteo restringido a $\mathcal{W}_{\text{obs}}$
`monetary_total`	Frequency	$\sum_{o \in \mathcal{W}_{\text{obs}}} \text{amount}(o)$	Suma sobre $\mathcal{W}_{\text{obs}}$ únicamente
`monetary_avg_order`	Frequency	$\frac{\text{monetary_total}}{\text{frequency_orders}}$	Derivada de features sin leakage
`spending_intensity`	Intensity	$\frac{\text{monetary_total}}{90}$	Gasto por día en $\mathcal{W}_{\text{obs}}$
`trend_slope_30d`	Trend	Pendiente OLS de gasto semanal en últimos 30d $\subseteq \mathcal{W}_{\text{obs}}$	La subventana [30d, t_0] $\subset \mathcal{W}_{\text{obs}}$

Continúa en la siguiente página

Feature	**Familia**	**Fórmula**	**Argumento Anti-Leakage**
`category_diversity`	Diversity	$\lvert\{c : c \in \text{categorías}(\mathcal{W}_{\text{obs}})\}\rvert$	Conteo de categorías únicas en $\mathcal{W}_{\text{obs}}$
`support_tickets_90d`	Intensity	$\lvert\{t : t.\text{date} \in \mathcal{W}_{\text{obs}}\}\rvert$	Tickets creados antes de t_0
`avg_delivery_days`	Intensity	$\text{mean}(\text{delivery_date} - \text{order_date})$ sobre $\mathcal{W}_{\text{obs}}$	Ambas fechas $\leq t_0$
`return_rate`	Intensity	$\frac{\lvert\{o \in \mathcal{W}_{\text{obs}} : \text{status} = \text{RETURNED}\}\rvert}{\lvert\{o \in \mathcal{W}_{\text{obs}}\}\rvert}$	Numerador y denominador en $\mathcal{W}_{\text{obs}}$
`days_since_registration`	Recency	$t_0 - \text{registration_date}$	Fecha de registro es histórica
`preferred_category`	Diversity	$\arg\max_c \lvert\{o \in \mathcal{W}_{\text{obs}} : \text{cat}(o) = c\}\rvert$	Moda de categorías en $\mathcal{W}_{\text{obs}}$
`customer_segment`	Diversity	Campo `dim_customers.customer_segment`	Atributo de la dimensión, sin historia futura

Importancia de Variables

El análisis de importancia basado en SHAP (SHapley Additive exPlanations) revela que las tres features con mayor contribución predictiva son: (a) `recency_days` ($\phi_{\text{SHAP}} = 0.34$), (b) `trend_slope_30d` ($\phi_{\text{SHAP}} = 0.21$), y (c) `support_tickets_90d` ($\phi_{\text{SHAP}} = 0.18$). Estos hallazgos son consistentes con la literatura de churn: la recencia es el predictor más fuerte de abandono en e-commerce (Fader et al., 2005).

Conclusiones

El sistema implementado satisface todos los requisitos del Analytics Contract definido en la Fase I. El modelo XGBoost con ajuste dinámico de umbral alcanza un Recall de 0.82 [IC95%: 0.80, 0.84], superando en un 82.2% al mejor baseline heurístico (RFM, Recall = 0.45) y validando la hipótesis de que el aprendizaje automático puede identificar churners potenciales con precisión estadísticamente significativa.

Las contribuciones principales del trabajo son: (a) un pipeline reproducible de nivel de proyecto, (b) un protocolo de prevención de *data leakage* con verificación formal, (c) un Evidence Bundle que garantiza la auditabilidad de cada resultado, y (d) una arquitectura de Feature Store que permite el despliegue en producción sin modificaciones al código de entrenamiento.

Como trabajo futuro, se recomienda: (a) implementar monitoreo de *data drift* para detectar cambios en la distribución de features en producción (Gama et al., 2014), (b) diseñar un experimento A/B controlado para validar la hipótesis de negocio, y (c) explorar modelos de supervivencia (Kaplan-Meier, Cox) para estimar el tiempo hasta el abandono, no solo si ocurrirá.

Evidence Bundle Index

El Evidence Bundle Index mapea cada afirmación del informe con su artefacto de soporte y el comando exacto de replicación, garantizando la Reproducibilidad a Nivel de Proyecto (Amortegui, 2026):

Tabla 6: *Evidence Bundle Index: Mapeo Claim → Artefacto → Comando*

Afirmación (Claim)	**Artefacto**	**Comando de Reproducción**	**Sección**
dup_rate = 0% en todas las tablas	`artifacts/manifest.json` → `feature_matrix.md`	`python main.py -skip-train`	§4
Recall = 0.82 [0.80, 0.84]	`artifacts/models/model.pkl`	`python main.py`	§6
Lift@20% = 2.4x	`artifacts/figures/lift_curve.png`	`python main.py`	§6
Feature `recency_days`: top SHAP	`artifacts/figures/shap_summary.png`	`python main.py`	§7
Zero leakage temporal	`artifacts/manifest.json` → `cutoff_date`	`artifacts/manifest.json`	§3
Distribución de clases 10.2% churn	`artifacts/figures/class_distribution.png`	`python main.py -skip-train`	§4

Continúa...

Afirmación (Claim)	**Artefacto**	**Comando**	**Sec.**
Baseline RFM Recall = 0.45	artifacts/models/model.pkl (baseline_rfm en eval)	python main.py	§6
Pipeline reproducible (hash MD5)	artifacts/manifest.json	python main.py && cat artifacts/manifest.json	§5

Instrucción de Replicación Completa:

Listing 2: Protocolo de Reproducción para Evaluador Externo

```
# 1. Clonar repositorio
git clone <url_repositorio>
cd "proyecto␣1"

# 2. Instalar dependencias (Python 3.9+)
pip install -r requirements.txt

# 3. Ejecutar pipeline completo (seed incluido)
python main.py

# 4. Verificar artefactos generados
cat artifacts/manifest.json | python -m json.tool

# 5. Comparar hash MD5 con los reportados en este documento
# Resultado esperado: hash identico (semilla = 245573)
```

Referencias

Amortegui, S. (2026). *Proyecto de Ciencia de Datos II: Guía de proyecto*. Universidad de La Sabana, Facultad de Ingeniería.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Davis, J., & Goadrich, M. (2006). The relationship between precision-recall and ROC curves. *Proceedings of the 23rd International Conference on Machine Learning*, 233–240. https://doi.org/10.1145/1143844.1143874

Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005). RFM and CLV: Using iso-value curves for customer base analysis. *Journal of Marketing Research*, *42*(4), 415–430. https://doi.org/10.1509/jmkr.2005.42.4.415

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, *46*(4), 1–37. https://doi.org/10.1145/2523813

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, *30*, 4765–4774.

Reichheld, F. F., & Schefter, P. (2000). E-loyalty: Your secret weapon on the web. *Harvard Business Review*, *78*(4), 105–113.

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, *63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, *28*, 2503–2511.